UNIVERSIDADE PRESBITERIANA MACKENZIE

CURSO DE BANCO DE DADOS

DISCIPLINA: PROJETO APLICADO 1

GRUPO 10

BEATRIZ RESENDE SILVA - 10775947 -
BEATRIZRESENDE.SILVA@MACKENZISTA.COM.BR

MAYARA LAURY GONÇALVES DE FRANÇA - 10763877 -
MAYARALAURY.FRANÇA@MACKENZISTA.COM.BR

MELISSA MENCHÃO LIMA DO NASCIMENTO - 10764865 -
MELISSAMENCHAO.NASCIMENTO@MACKENZISTA.COM.BR

OTAVIO PRATES DOS SANTOS - 10775492 -
OTAVIOPRATES.SANTOS@MACKENZISTA.COM.BR

https://github.com/melissalima308/mackenzie-grupo10-projeto-bd

SÃO PAULO

2026

SUMÁRIO

1. QUEM É A OLIST 5
1.1 HISTÓRICO E TRAJETÓRIA 5
1.2 ÁREA DE ATUAÇÃO E ABRANGÊNCIA GEOGRÁFICA 5
1.3 NÚMERO DE CLIENTES E PORTE 5
1.4 FATURAMENTO 6
1.5 CAPTAÇÃO DE INVESTIMENTO E AVALIAÇÃO DE MERCADO 6
1.6 CONTEXTO DE GERAÇÃO DOS DADOS E RELAÇÃO COM AS ATIVIDADES DA ORGANIZAÇÃO 6
1.7 PREMISSAS, OBJETIVOS E APLICAÇÃO DO PENSAMENTO COMPUTACIONAL 6
1.8 RELAÇÃO COM OS OBJETIVOS DE DESENVOLVIMENTO SUSTENTÁVEL (ODS) 7
2. REFERÊNCIAS DE AQUISIÇÃO DOS DADOS 8
2.1 ORIGEM E FORMA DE OBTENÇÃO 8
2.2 PERÍODO DA COLETA 8
2.3 LICENCIAMENTO E RESTRIÇÕES DE USO 8
3. APRESENTAÇÃO E DESCRIÇÃO DO DATASET 8
3.1 DESCRIÇÃO DO CONTEÚDO, VARIÁVEIS E ESTRUTURA 10
3.2 PROPOSTA DO CONJUNTO DE DADOS E FINALIDADE DE USO 10
3.3 PROBLEMAS, FENÔMENOS E COMPORTAMENTOS QUE PODERÃO SER ANALISADOS 11
3.4 MODELAGEM RELACIONAL DO CONJUNTO DE DADOS 11
4. ANÁLISE EXPLORATÓRIA DE DADOS 12
4.1 ESTRUTURA E QUALIDADE DOS DADOS 12
4.2 PERFIL DOS PEDIDOS E SAZONALIDADE 13
4.3 DESEMPENHO LOGÍSTICO 13
4.4 SATISFAÇÃO DO CLIENTE 14
4.5 PAGAMENTOS, PREÇOS E CATEGORIAS 15
4.6 DISTRIBUIÇÃO GEOGRÁFICA E CONCENTRAÇÃO DE VENDEDORES 17
5. PROPOSTA ANALÍTICA 18
5.1 HIPÓTESES DE INVESTIGAÇÃO 18
5.2 METODOLOGIA 19
6. STORYTELLING 20
6.1 IDEIA CENTRAL E PÚBLICO 20
6.2 ESTRUTURA NARRATIVA 20
6.3 RECOMENDAÇÕES 21
6.4 LIMITAÇÕES 22
7. SCRIPTS DA ANÁLISE EXPLORATÓRIA REVISADOS 22
8.1 ORGANIZAÇÃO DO CÓDIGO 22
7.1 REVISÕES REALIZADAS NESTA ETAPA 23
7.2 RESULTADOS DA REVISÃO 23
8. REPOSITÓRIO E DASHBOARD 24

CRONOGRAMA.....25
REFERÊNCIAS 26

LISTA DE ILUSTRAÇÕES

FIGURAS

Figura 1 – Esquema de Dados.....8

GRÁFICOS

Gráfico 1 – Pedidos por mês (2016-2018).....13
Gráfico 2 – Distribuição do tempo de entrega.....14
Gráfico 3 – Distribuição das notas 14
Gráfico 4 – Nota média: no prazo x atrasado 15
Gráfico 5 – Pagamentos por forma de pagamento 16
Gráfico 6 – Top 10 categorias por número de pedidos.....16
Gráfico 7 – Top 10 Estados: Clientes x vendedores por estado 17
Gráfico 8 – Concentração de receita entre vendedores 18

1. QUEM É A OLIST

A Olist se define como uma parceira do empreendedor brasileiro, com a missão de "fortalecer negócios e impulsionar vidas" no varejo. A empresa não opera como uma loja própria, mas como um ecossistema de tecnologia que conecta pequenos e médios lojistas brasileiros a canais de venda (marketplaces como Mercado Livre, Amazon, Shopee, entre outros) e oferece um conjunto integrado de soluções: Sistema ERP, Hub de Integração com marketplaces, Conta Digital/Crédito, Sistema de PDV para loja física, criação de loja virtual (E-commerce) e, mais recentemente, uma vertical de logística (Envios da Olist).

1.1 HISTÓRICO E TRAJETÓRIA

Segundo a própria página institucional, a empresa foi fundada em 2007 como Solidarium, como uma loja física de artesanato dentro de shopping centers; em 2011, mudou para um modelo de marketplace; em 2015, tornou-se Olist e captou o primeiro investimento; em 2019 e 2020, levantou os aportes de série C (SoftBank, R$ 190 milhões) e série D (R$ 360 milhões, que se estendeu em 2021); em 2021, adquiriu ERP Tiny e plataforma de e-commerce Vnda; e em 2023 se tornou um unicórnio latino-americano após uma rodada de série E.

1.2 ÁREA DE ATUAÇÃO E ABRANGÊNCIA GEOGRÁFICA

A atuação é em âmbito nacional, de lojistas de vários portes e de todo o Brasil, com sede na cidade de Curitiba (PR), e sua headquarters localiza-se na Avenida Cândido Hartmann, 590, na capital paranaense. Em recente reportagem publicada pela Bloomberg Línea, quando se tratava do lançamento da divisão de logística "Envios da Olist", foi reportado que o serviço já atendia lojistas de 162 cidades no momento do lançamento.

1.3 NÚMERO DE CLIENTES E PORTE

As informações públicas da base de lojistas também variam conforme a data de suas fontes e o produto abordado: uma matéria de 2024 já citava mais de 50 mil pequenos e médios lojistas na conta digital da empresa, enquanto páginas comerciais mais atuais do próprio site falam em "mais de 45 mil lojistas" na plataforma de e-commerce e em alcançar "mais de 60 mil lojistas"

em parceiros tecnológicos. Isso corresponde a dezenas de milhares de pequenos e médios negócios, e uma base em expansão.

1.4 FATURAMENTO

A Olist não revela faturamento em valores absolutos. Em entrevista à Bloomberg Línea, o fundador e CEO da Olist, Tiago Dalvi, declarou que o crescimento da empresa é de "dois dígitos altos", mas que não abriu valores absolutos ou percentuais e deveria chegar ao breakeven (ponto de equilíbrio financeiro) ainda em 2025.

1.5 CAPTAÇÃO DE INVESTIMENTO E AVALIAÇÃO DE MERCADO

A Olist se tornou uma empresa unicórnio (avaliação de mercado superior a US$ 1 bilhão) desde 2021, quando recebeu um investimento de US$ 186 milhões em rodada Série E liderado pelo fundo Wellington Management. De acordo com a CB Insights, o fundador e CEO da empresa é Tiago Dalvi.

1.6 CONTEXTO DE GERAÇÃO DOS DADOS E RELAÇÃO COM AS ATIVIDADES DA ORGANIZAÇÃO

O dataset disponibilizado no Kaggle tem sido coletado, anonimizados e tratados de dados de pedidos de compra realizados na loja online "Olist Store". A ordem pode conter várias compras e cada produto comprado (item) pode ser de fornecedor (seller) diferente. Após a entrega (ou até data limite estimada) o cliente receberá um email de pesquisa de satisfação e isso formará a base das avaliações (reviews) do dataset, ou seja, os dados são provenientes do próprio modelo de negócio principal da empresa: a intermediação entre lojistas de menor porte, marketplaces e consumidores.

1.7 PREMISSAS, OBJETIVOS E APLICAÇÃO DO PENSAMENTO COMPUTACIONAL

- Premissa: os dados operacionais de uma plataforma de marketplace (pedidos, pagamentos, logística e avaliações) contêm padrões que podem ser identificados por meio de técnicas de análise de dados e programação.

- Objetivo geral: aplicar as etapas do pensamento computacional (decomposição, reconhecimento de padrões, abstração e construção de algoritmos) para investigar o funcionamento do e-commerce brasileiro a partir do caso Olist.
- Metas específicas: quebrar o problema de negócio em subproblemas analisáveis (por exemplo, performance logística, satisfação do cliente, comportamento de compra); criar a estrutura de um banco de dados relacional a partir dos arquivos CSV; e criar insights que sustentem a tomada de decisão (por exemplo, gargalos de atraso na entrega, categorias mais bem avaliadas).
- Contextualização com organização: o projeto é contextualizado por simular o trabalho de uma equipe de dados em uma empresa de tecnologia para varejo, convertendo dados brutos operacionais em informações estruturadas que podem ser usadas para decisões;

1.8 RELAÇÃO COM OS OBJETIVOS DE DESENVOLVIMENTO SUSTENTÁVEL (ODS)

A partir do modelo de negócio descrito (ligando pequenos empreendedores de diferentes regiões do país a canais digitais de venda), podemos relacionar a atuação da Olist principalmente aos seguintes ODS:

- ODS 8 – Trabalho decente e crescimento econômico: por meio da formalização e da viabilização de operações de pequenos e médios negócios no e-commerce, a empresa colabora para a geração de renda e para a inclusão produtiva de micro e pequenos empreendedores.
- ODS 9 – Indústria, inovação e infraestrutura: a empresa fornece infraestrutura tecnológica (ERP, hub de integração, logística) que atualiza a operação de varejistas que, individualmente, não teriam capacidade de acessar tecnologia avançada.
- ODS 10 – Redução das desigualdades: ao democratizar o acesso de lojistas de diferentes regiões do Brasil (inclusive fora dos grandes centros) aos mesmos canais de venda usados por grandes players, a plataforma reduz barreiras geográficas e de escala.

2. REFERÊNCIAS DE AQUISIÇÃO DOS DADOS

2.1 ORIGEM E FORMA DE OBTENÇÃO

O dataset foi baixado na plataforma Kaggle, publicado na íntegra pela própria Olist, com o nome "Brazilian E-Commerce Public Dataset by Olist", pelo usuário "olistbr", disponível em https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce.

2.2 PERÍODO DA COLETA

Segundo a descrição fornecida na própria página do dataset, ele contém informações de aproximadamente 100 mil pedidos realizados de 2016 a 2018 em diversos marketplaces no Brasil. Análises de terceiros feitas diretamente no próprio conjunto de dados tornam esse intervalo mais preciso, colocando a maioria dos registros de pedidos em 2017 e 2018.

2.3 LICENCIAMENTO E RESTRIÇÕES DE USO

De acordo com a própria página do dataset no Kaggle, a licença aplicada é a CC BY-NC-SA 4.0 (Atribuição-NãoComercial-CompartilhaIgual 4.0 Internacional), o que significa que o uso é permitido para fins educacionais e de pesquisa, mas não para exploração comercial direta, sendo necessário atribuir a fonte e manter a licença em obras derivadas. O dataset ainda apresenta, na própria plataforma, nota de "usabilidade" máxima (10.00), o que indica boa documentação e metadados.

3. APRESENTAÇÃO E DESCRIÇÃO DO DATASET

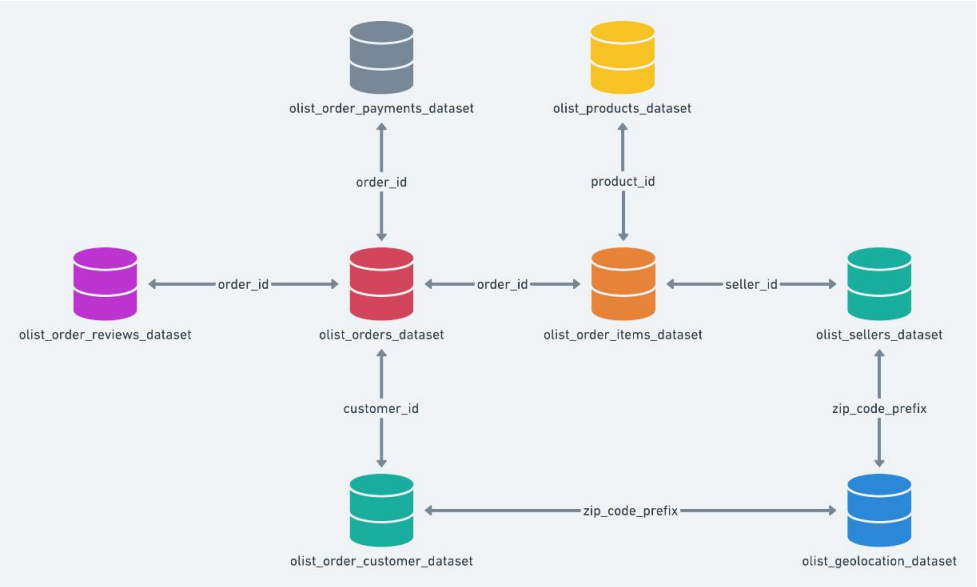
O conjunto de dados é composto por 9 arquivos no formato CSV, relacionados entre si por chaves como order_id, customer_id, product_id, seller_id e código postal:

Arquivo	**Descrição**
olist_orders_dataset.csv	Contém os dados centrais dos pedidos realizados na plataforma, incluindo status do pedido, datas de compra, aprovação do pagamento, envio e entrega estimada e real.

olist_order_items_dataset.csv	Apresenta os itens que compõem cada pedido, contendo informações como identificador do produto, preço e prazo limite de envio definido pelo vendedor.
olist_order_payments_dataset.csv	Registra os dados de pagamento dos pedidos, incluindo forma de pagamento utilizada, quantidade de parcelas e valor pago pelo cliente.
olist_order_reviews_dataset.csv	Reúne as avaliações dos clientes, com nota de satisfação de 1 a 5, título e comentário da avaliação, além das datas de criação e resposta.
olist_customers_dataset.csv	Contém informações dos clientes, incluindo identificador único e dados de localização, como cidade, estado e CEP.
olist_sellers_dataset.csv	Armazena informações dos vendedores cadastrados na plataforma, incluindo identificador único e localização geográfica.
olist_products_dataset.csv	Apresenta informações dos produtos comercializados, como categoria, dimensões e características físicas.
olist_geolocation_dataset.csv	Relaciona CEPs brasileiros com coordenadas geográficas de latitude e longitude, permitindo análises espaciais e geográficas.
product_category_name_translation.csv	Contém a tradução dos nomes das categorias de produtos do português para o inglês, facilitando análises internacionais e padronização dos dados.

Esquema de dados apresentado no Kaggle:

Figura 1 - Esquema de Dados



Fonte: OLIST. Brazilian E-Commerce Public Dataset by Olist. Kaggle.

3.1 DESCRIÇÃO DO CONTEÚDO, VARIÁVEIS E ESTRUTURA

A análise realizada diretamente sobre os arquivos mostra que o conjunto reúne 99.441 pedidos, 99.441 identificadores de cliente (correspondentes a 96.096 clientes únicos) e 3.095 vendedores. A soma do preço dos itens vendidos é de aproximadamente R$ 13,59 milhões (R$ 13,22 milhões considerando apenas os pedidos entregues). Já a soma dos valores registrados na tabela de pagamentos é de aproximadamente R$ 16,01 milhões, valor maior por incluir, entre outros componentes, o frete, que soma R$ 2,25 milhões. A estrutura permite visualizar um pedido sob diversas dimensões: status do pedido, preço, forma de pagamento, desempenho do frete, localização do cliente, atributos do produto e, finalmente, avaliações escritas pelos consumidores.

3.2 PROPOSTA DO CONJUNTO DE DADOS E FINALIDADE DE USO

De acordo com a própria página do Kaggle, algumas possíveis finalidades de uso são explicitadas: previsão de vendas baseado na data de compra; análise de performance de entregas, tentando encontrar meios de aprimorar o tempo para o produto ser enviado; análise de qualidade de produto, identificando se certas categorias tendem a mais insatisfação do

cliente, e engenharia de atributos (feature engineering), inclusive tendo a possibilidade de utilizar tal dataset em combinação com um "Marketing Funnel Dataset" complementar, também disponibilizado pela Olist.

3.3 PROBLEMAS, FENÔMENOS E COMPORTAMENTOS QUE PODERÃO SER ANALISADOS

- Correlação entre tempo de entrega (real x estimado) e nota de satisfação do cliente.
- Densidade de vendedores e compradores, e assim assimetrias regionais de acesso ao comércio eletrônico (talvez até na discussão de possíveis indicadores dos ODS).
- Padrões de forma de pagamento (à vista, cartão parcelado, boleto) e seu efeito no ticket médio.
- Performance por categoria de produto: quais categorias possuem mais pedidos, maior valor médio ou mais reclamações.
- Sazonalidade de vendas ao longo do período 2016–2018.
- Relação entre valor do frete e insatisfação do cliente.
- Venda concentrada entre poucos vendedores ("cauda longa" efeito de concentração em poucos sellers).

3.4 MODELAGEM RELACIONAL DO CONJUNTO DE DADOS

Os nove arquivos foram carregados em um banco de dados relacional SQLite, com chaves primárias, chaves estrangeiras e índices declarados, o que atende à meta específica definida no item 1.7. A construção do modelo exigiu três decisões que o formato CSV não revela.

A tabela de avaliações não admite chave primária simples. São 99.224 linhas para 98.410 valores distintos de review_id e 98.673 de order_id, de modo que nenhum dos dois campos identifica unicamente um registro. A chave primária adotada é composta por (review_id, order_id).

A tabela de geolocalização não possui chave natural. Cerca de 26% das linhas são duplicadas integrais, resultado de um mesmo prefixo de CEP associado a diferentes pares de coordenadas. A tabela foi mantida sem chave primária, com índice sobre o prefixo.

A tabela de tradução de categorias não cobre todas as categorias presentes em produtos, o que impediria o fechamento da chave estrangeira. As categorias ausentes foram inseridas na tabela de referência com tradução nula, preservando o relacionamento.

A integridade referencial foi verificada em dois momentos, antes da carga por comparação de conjuntos de chaves e depois da carga pelo comando PRAGMA foreign_key_check do próprio SQLite. Nenhum registro órfão foi encontrado em nenhum dos seis relacionamentos do modelo.

4. ANÁLISE EXPLORATÓRIA DE DADOS

A análise exploratória teve como objetivo conhecer a estrutura, a qualidade e os principais comportamentos presentes nos nove arquivos do dataset da Olist, usando Python (bibliotecas pandas e matplotlib). Os resultados orientam a proposta analítica apresentada nesta etapa.

4.1 ESTRUTURA E QUALIDADE DOS DADOS

O dataset reúne 99.441 pedidos, 112.650 itens vendidos, 103.886 registros de pagamento, 99.224 avaliações, 3.095 vendedores e 32.951 produtos. Há 99.441 identificadores de cliente (customer_id), correspondentes a 96.096 clientes únicos (customer_unique_id). A tabela de geolocalização é a maior, com mais de 1 milhão de linhas.

Nenhuma tabela apresentou valores nulos em colunas de identificação ou de valores financeiros. Os nulos se concentram em campos opcionais ou dependentes do andamento do pedido:

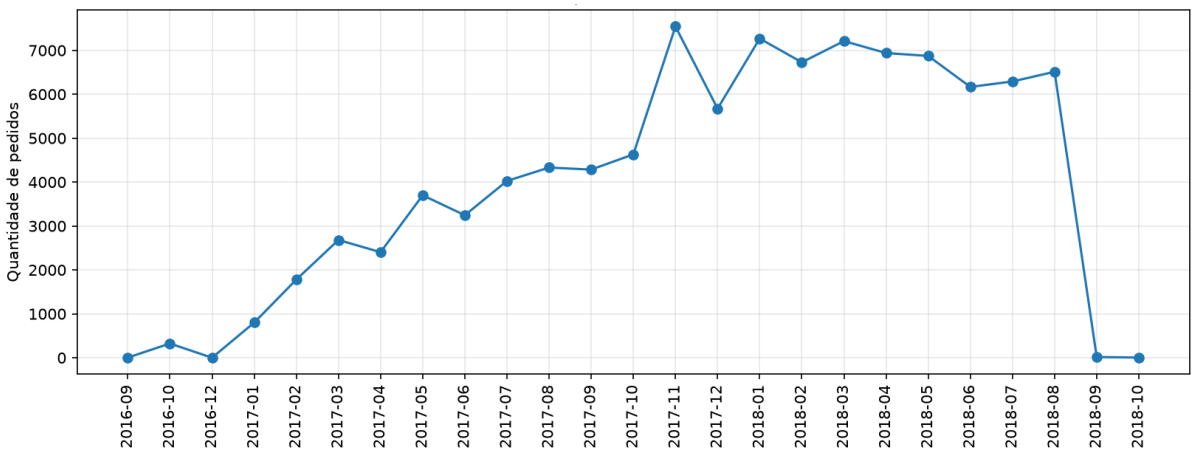
- **Avaliações:** 88,34% sem título e 58,70% sem comentário, o que é esperado, pois o texto é opcional.
- **Pedidos:** 2,98% sem data de entrega ao cliente (2.965 pedidos), coerente com pedidos cancelados ou ainda em trânsito.
- **Produtos:** 610 produtos (1,85%) sem categoria e sem atributos descritivos, o que deixa 1.603 itens vendidos sem categoria.

A única tabela com linhas duplicadas é a de geolocalização (261.831 linhas, cerca de 26%), provavelmente por haver várias coordenadas para o mesmo prefixo de CEP. As demais não têm duplicidades.

4.2 PERFIL DOS PEDIDOS E SAZONALIDADE

As compras vão de setembro de 2016 a outubro de 2018, mas a cobertura é desigual. Em 2016 há apenas 329 pedidos (nenhum em novembro), e setembro e outubro de 2018 têm apenas 20, indicando o fim da base. O período mais consistente vai de janeiro de 2017 a agosto de 2018.

Gráfico 1 — Pedidos por mês (2016-2018)



Fonte: Elaborado pelos autores a partir de dados da Olist (Kaggle, 2026).

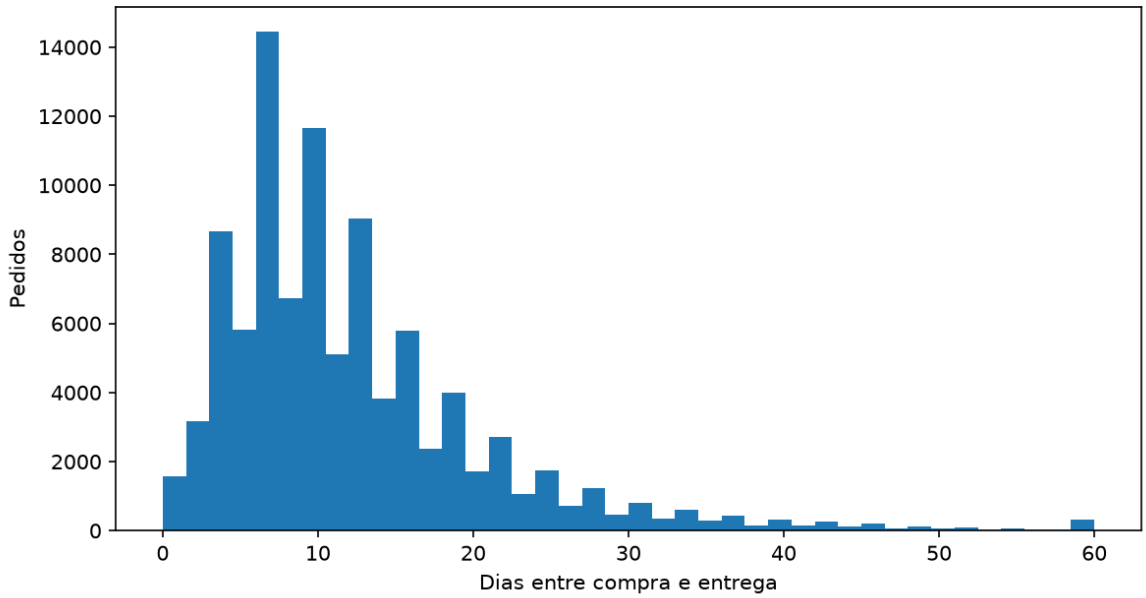
O volume cresce ao longo de 2017, com pico em novembro (7.544 pedidos), possivelmente associado à Black Friday, e se estabiliza entre 6.000 e 7.300 pedidos mensais em 2018. Quanto ao status, 97,02% dos pedidos foram entregues; o restante se divide entre enviados (1,11%), cancelados (0,63%), indisponíveis (0,61%) e demais etapas.

4.3 DESEMPENHO LOGÍSTICO

Nos 96.470 pedidos entregues, o tempo médio entre compra e entrega foi de 12,09 dias (mediana de 10), enquanto o prazo estimado médio foi de 23,37 dias. A Olist estima prazos bem maiores que o tempo real, e apenas 8,11% das entregas chegaram depois da data estimada. Há casos extremos, com até 209 dias.

A definição de atraso exige um critério explícito. O campo order_estimated_delivery_date registra apenas a data, sempre com hora 00:00:00, enquanto order_delivered_customer_date registra data e hora. Adotou-se neste trabalho a comparação por data e hora, que trata a data estimada como prazo com vencimento à meia-noite e resulta em 8,11% de entregas atrasadas. A comparação por dia de calendário, que consideraria dentro do prazo uma entrega realizada no próprio dia estimado após a meia-noite, resultaria em 6,77%. A diferença entre os dois critérios corresponde a 1.292 pedidos, e o critério adotado é o mais conservador.

Gráfico 2 – Distribuição do tempo de entrega

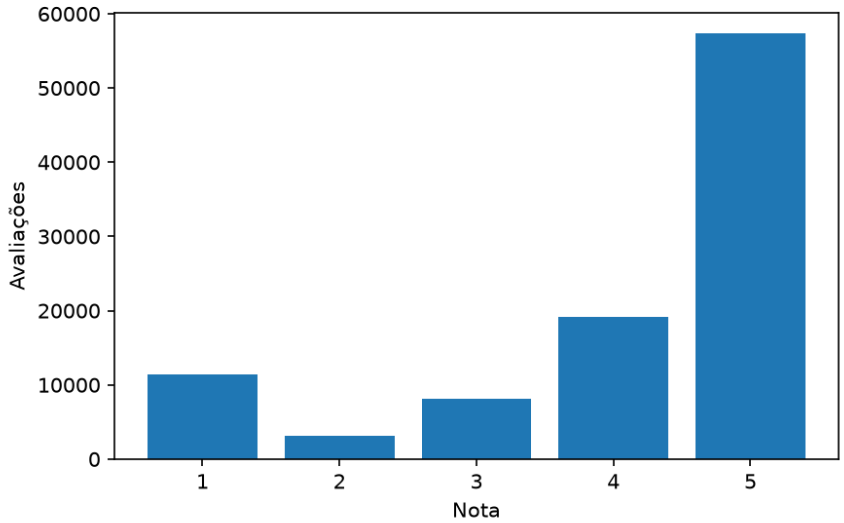


Fonte: Elaborado pelos autores a partir de dados da Olist (Kaggle, 2026).

4.4 SATISFAÇÃO DO CLIENTE

A nota média é 4,09, e 77,07% das avaliações são 4 ou 5. As notas 1 e 2 somam 14,69%.

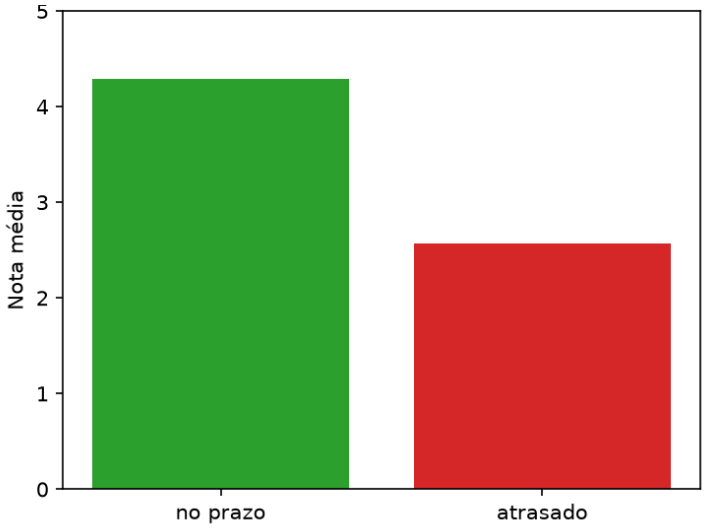
Gráfico 3 – Distribuição das notas



Fonte: Elaborado pelos autores a partir de dados da Olist (Kaggle, 2026).

O atraso na entrega se relaciona fortemente com a satisfação: pedidos no prazo têm nota média de 4,29, e pedidos atrasados, 2,57. A correlação de Spearman entre tempo de entrega e nota é de -0,235, negativa e moderada-fraca. O valor do frete tem relação mais tênue (-0,087).

Gráfico 4 – Nota média: no prazo x atrasado



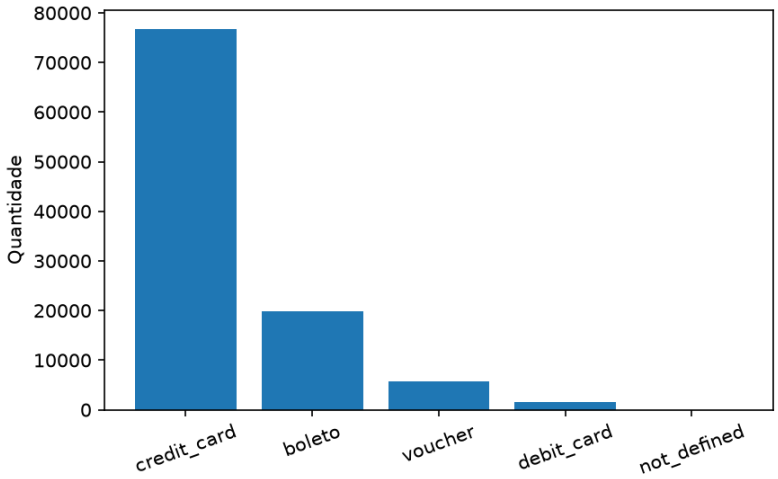
Fonte: Elaborado pelos autores a partir de dados da Olist (Kaggle, 2026).

4.5 PAGAMENTOS, PREÇOS E CATEGORIAS

Forma de pagamento	**Registros**	**%**	**Valor médio (R$)**
Cartão de crédito	76.795	73,9%	163,32
Boleto	19.784	19,0%	145,03
Voucher	5.775	5,6%	65,70
Cartão de débito	1.529	1,5%	142,57

O cartão de crédito domina (cerca de 78% do valor total pago), com média de 3,51 parcelas; as demais formas são sempre à vista. O ticket mediano por pedido é de R$ 105,29 e a média, R$ 160,99, o que indica assimetria à direita. O mesmo vale para o preço dos itens (mediana de R$ 74,99, média de R$ 120,65 e máximo de R$ 6.735). O frete médio é R$ 19,99.

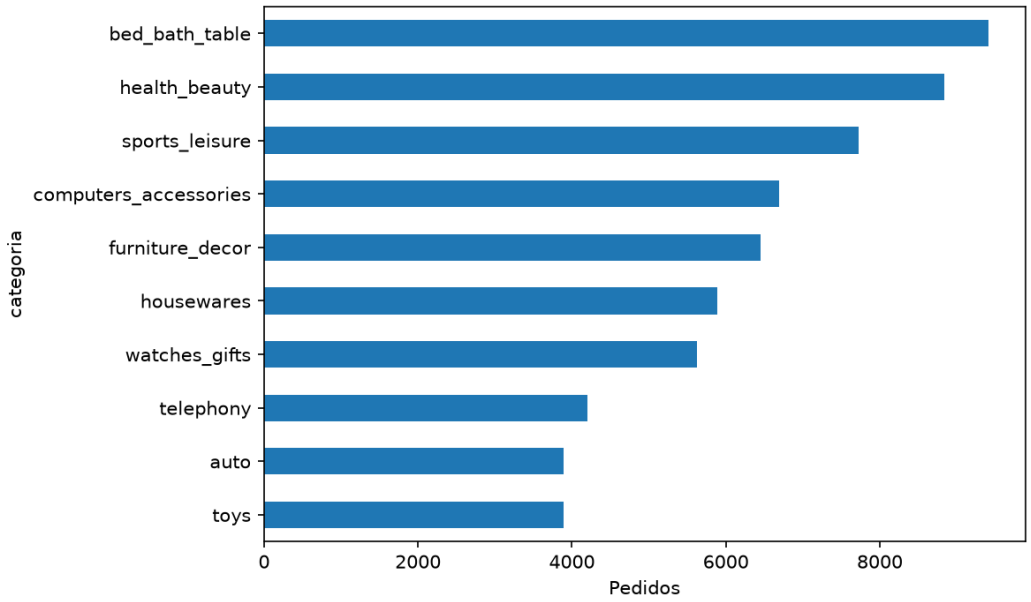
Gráfico 5 – Pagamentos por forma de pagamento



Fonte: Elaborado pelos autores a partir de dados da Olist (Kaggle, 2026).

Entre as categorias, *bed_bath_table* lidera em pedidos (9.417), enquanto *health_beauty* lidera em receita (R$ 1,26 milhão). *Watches_gifts* se destaca pelo maior preço médio entre as principais (R$ 201,14). Nas avaliações, a pior nota média é de *office_furniture* (3,62) e a melhor, de *books_general_interest* (4,46), considerando categorias com ao menos 100 pedidos.

Gráfico 6 – Top 10 categorias por número de pedidos



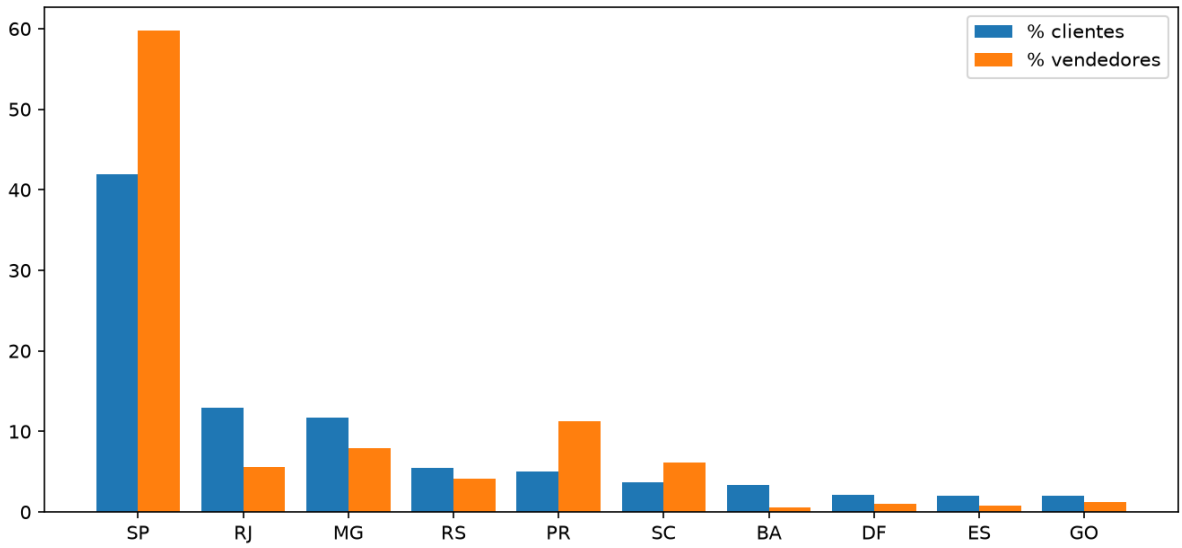
Fonte: Elaborado pelos autores a partir de dados da Olist (Kaggle, 2026).

4.6 DISTRIBUIÇÃO GEOGRÁFICA E CONCENTRAÇÃO DE VENDEDORES

UF	% dos clientes	% dos vendedores
SP	41,98%	59,74%
RJ	12,92%	5,53%
MG	11,70%	7,88%
PR	5,07%	11,28%
BA	3,40%	0,61%

São Paulo, Rio de Janeiro e Minas Gerais reúnem 66,6% dos clientes, e São Paulo, Paraná e Minas Gerais reúnem 78,9% dos vendedores. Estados como a Bahia têm proporção de clientes cinco vezes maior que a de vendedores (19 no total), o que sugere assimetria de acesso entre regiões.

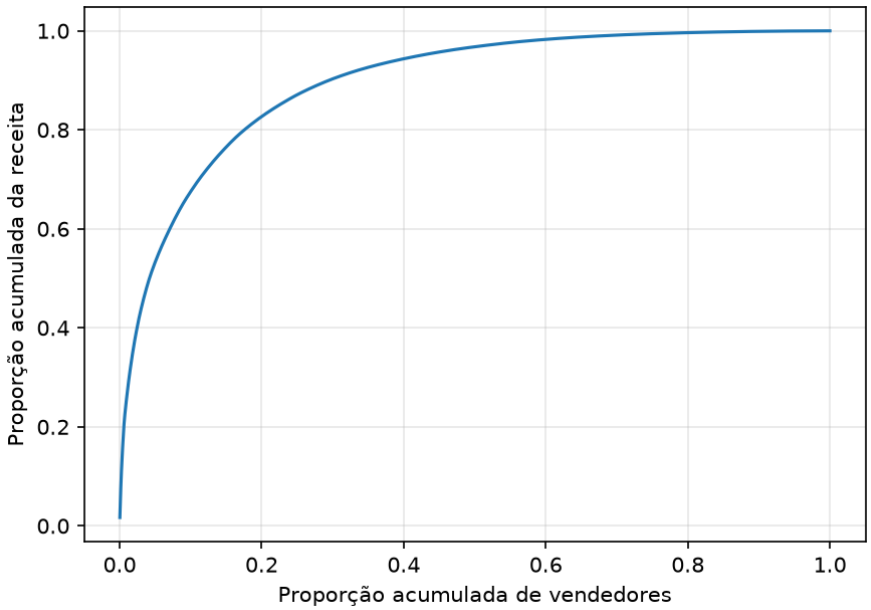
Gráfico 7 – Top 10 Estados: Clientes x vendedores por estado



Fonte: Elaborado pelos autores a partir de dados da Olist (Kaggle, 2026).

A receita é bastante concentrada: o 1% de vendedores mais relevantes (30) responde por 25,67% da receita, os 10% mais relevantes (309) por 67,49%, e os 20% mais relevantes (619) por 82,69%.

Gráfico 8 – Concentração de receita entre vendedores



Fonte: Elaborado pelos autores a partir de dados da Olist (Kaggle, 2026).

5. PROPOSTA ANALÍTICA

A proposta analítica tem como objetivo aprofundar os principais padrões identificados na análise exploratória, transformando os achados observados em questões de investigação que possam ser analisadas a partir dos dados da Olist.

5.1 HIPÓTESES DE INVESTIGAÇÃO

A partir dos resultados obtidos na análise exploratória, foram definidas duas hipóteses de investigação. As hipóteses buscam aprofundar relações identificadas entre logística, satisfação dos clientes, características dos produtos e valores associados aos pedidos.

H1 – Relação entre atraso na entrega e satisfação do cliente

Quanto maior o atraso na entrega do pedido em relação à data estimada, menor tende a ser a avaliação atribuída pelo cliente?

A hipótese foi definida a partir do padrão identificado na análise exploratória, que indicou diferenças relevantes na satisfação dos clientes entre pedidos entregues no prazo e pedidos

atrasados. Na proposta analítica, essa relação é aprofundada considerando diferentes níveis de atraso, permitindo verificar se a satisfação varia de acordo com a intensidade do atraso.

H2 – Categoria e desempenho dos pedidos

O desempenho dos pedidos varia de acordo com a categoria dos produtos, considerando o volume de pedidos, a receita gerada e a avaliação média dos clientes?
Essa hipótese foi definida a partir das diferenças observadas entre as categorias de produtos na análise exploratória, na qual foram identificadas categorias com destaque em volume de pedidos, receita e avaliação média.

5.2 METODOLOGIA

Para investigar as hipóteses propostas, foi utilizada a linguagem Python, com apoio das bibliotecas Pandas, para manipulação e análise dos dados, e Matplotlib, para construção das visualizações. Essas ferramentas também foram utilizadas na análise exploratória desenvolvida anteriormente no projeto.

H1 – Atraso na entrega e satisfação do cliente

Para investigar a primeira hipótese, foram utilizados os dados de pedidos e avaliações dos clientes. Inicialmente, foram consideradas as datas de entrega efetiva e de entrega estimada para calcular a diferença entre as duas, adotando a comparação por data e hora descrita na seção 4.3. As avaliações foram agregadas por pedido, considerando a média das notas atribuídas aos clientes. Em seguida, os pedidos foram classificados em cinco faixas de acordo com o atraso observado: no prazo, 1–3 dias, 4–7 dias, 8–14 dias e mais de 14 dias.
Para cada faixa, foi calculada a nota média dos pedidos. Também foi analisada a distribuição percentual das avaliações em diferentes faixas de nota, permitindo observar como o perfil de satisfação se modifica conforme aumenta o atraso.

H2 – Categoria e desempenho dos pedidos

Para investigar a segunda hipótese, serão relacionados os dados de produtos, itens dos pedidos e avaliações, permitindo comparar as categorias de produtos segundo diferentes indicadores de desempenho.

Serão analisados o volume de pedidos, a receita gerada e a avaliação média dos clientes para cada categoria. A análise permitirá identificar se determinadas categorias apresentam desempenho superior ou inferior de acordo com os diferentes indicadores considerados.

6. STORYTELLING

O storytelling com dados organiza os resultados da análise exploratória e das hipóteses em uma narrativa com início, conflito e desfecho, de modo que cada visualização sustente uma única mensagem e todas conduzam a uma conclusão acionável (KNAFLIC, 2019). Esta seção apresenta o esboço dessa narrativa, que servirá de base para a apresentação final e para o painel interativo do projeto.

6.1 IDEIA CENTRAL E PÚBLICO

A ideia central que conduz a narrativa é: **o cliente da Olist tolera a espera, mas não a promessa quebrada**. A satisfação se mantém enquanto o pedido chega dentro do prazo estimado, cai de forma acentuada a partir do segundo dia de atraso, e esse efeito se concentra em regiões, categorias e vendedores específicos.

O público imaginado é a gestão de operações e logística de uma plataforma de marketplace, responsável por decidir onde investir em prazo de entrega e com quais categorias e vendedores trabalhar mais de perto. A escolha do público define o tom: menos descrição técnica e mais relação entre o achado e a decisão que ele permite tomar.

6.2 ESTRUTURA NARRATIVA

A narrativa segue a estrutura de contexto, conflito e resolução, com uma virada no meio que contraria a impressão inicial de que a operação vai bem.

1. **Contexto.** A Olist registrou 99.441 pedidos entre 2016 e 2018, com crescimento ao longo de 2017 e pico de 7.544 pedidos em novembro, mês da Black Friday. 97,02% dos pedidos foram entregues, o prazo estimado médio é de 23,37 dias e o tempo real médio é de 12,09 dias. Apenas 8,11% das entregas chegam depois do prazo.
2. **Virada.** Esses 8,11% concentram a insatisfação. A nota média dos pedidos entregues no prazo é 4,29; a dos pedidos atrasados é 2,57.
3. **Aprofundamento da H1.** A queda não é linear. Até o primeiro dia de atraso a nota média fica em 4,04; no terceiro dia cai para 3,18 e no quarto para 2,68. A partir de oito dias de atraso, 78,15% das avaliações são notas 1 ou 2. Em sentido oposto, entregar com

muita antecedência pouco melhora a nota: pedidos entregues 20 dias antes do prazo têm média de 4,31, próxima dos entregues no limite.

4. **Aprofundamento da H2.** As dez categorias de maior receita somam 62,36% do faturamento. Entre as 52 categorias com ao menos 100 pedidos, 12 têm receita acima da mediana e nota abaixo da mediana, e respondem por cerca de 45% da receita analisada. O caso mais evidente é office_furniture, com a pior nota média (3,62), frete médio de R$ 40,55 e tempo médio de entrega de 20,17 dias, contra cerca de 12 dias no conjunto.
5. **Explicação estrutural.** São Paulo reúne 59,74% dos vendedores e 41,98% dos clientes. Entre os 27 estados, o percentual de entregas atrasadas e a nota média têm correlação de Spearman de -0,82: em Alagoas, 23,35% dos pedidos atrasam e a nota média é 3,85; em São Paulo, 5,83% e 4,25. A receita também é concentrada, com 10% dos vendedores respondendo por 67,49% do total.
6. **Resolução.** Recomendações derivadas diretamente dos achados, acompanhadas das limitações da análise.

6.3 RECOMENDAÇÕES

O desfecho da narrativa propõe três ações, cada uma vinculada a um achado:

- **Tratar o segundo dia de atraso como alerta.** Como a nota se mantém até o primeiro dia e cai de forma acentuada a partir do terceiro, pedidos que vão ultrapassar o prazo devem gerar aviso proativo ao cliente e prioridade de despacho antes desse ponto (H1).
- **Calibrar o prazo estimado.** A folga média de 11,28 dias entre prazo prometido e tempo real quase não melhora a nota e pode reduzir a conversão no momento da compra. O ganho está em estimar com mais precisão, e não em ampliar a folga (H1 e seção 4.3).
- **Priorizar categorias de receita alta e nota abaixo da mediana**, começando por office_furniture, cujo tempo de entrega é quase o dobro da média, e pelos estados com maior percentual de atraso (H2 e análise por estado).

Como desdobramento, propõe-se investigar o atraso por vendedor, já que 10% dos vendedores concentram 67,49% da receita. Essa análise não foi realizada nesta etapa e permanece como hipótese para trabalhos futuros.

6.4 LIMITAÇÕES

- **Associação não é causalidade.** Os dados mostram relação forte e consistente entre atraso e nota, por faixa, por dia e por estado, mas não isolam outros fatores, como defeito do produto ou atendimento do vendedor.
- **Período da base.** Os dados vão de 2016 a 2018 e retratam a operação anterior à vertical de logística própria da empresa. As recomendações valem como lógica, não como diagnóstico atual.
- **Critério de atraso.** Foi adotada a comparação por data e hora (8,11% de atrasos); por dia de calendário seriam 6,77%. O critério adotado é o mais conservador.
- **Quadrantes pela mediana.** O corte de nota é a mediana das categorias (4,105). Categorias próximas ao corte, como watches_gifts (4,07), são descritas como abaixo da mediana, e não como mal avaliadas.

7. SCRIPTS DA ANÁLISE EXPLORATÓRIA REVISADOS

Os scripts em Python desenvolvidos nas etapas anteriores foram revisados e publicados no repositório do grupo. O código está organizado em módulos com responsabilidades separadas e pode ser executado integralmente por um único comando, o que garante que todos os números deste relatório sejam reproduzíveis a partir dos arquivos originais do dataset.

8.1 ORGANIZAÇÃO DO CÓDIGO

Arquivo	Responsabilidade
executar.py	Orquestra o pipeline: carga, validação, banco SQLite, análise exploratória, H1, H2 e dashboard
src/config.py	Caminhos, parâmetros de análise (critério de atraso, faixas, mínimo de pedidos) e cores
src/carga.py	Leitura dos nove CSV, conversão de datas e verificação de integridade referencial
src/tratamento.py	Colunas derivadas: tempo de entrega, atraso, faixas de atraso e receita
src/banco.py	Criação do banco SQLite com chaves primárias, estrangeiras e índices
src/eda.py	Análise exploratória apresentada na seção 4
src/h1_atraso.py	Hipótese H1: nota por faixa, por dia e por estado, e testes estatísticos
src/h2_categoria.py	Hipótese H2: desempenho por categoria, Pareto e quadrantes
src/dashboard.py	Geração do painel interativo publicado no GitHub Pages

Arquivo	Responsabilidade
consultas/	Consultas SQL que reproduzem as análises diretamente no banco

7.1 REVISÕES REALIZADAS NESTA ETAPA

Revisão	Descrição
Análise por estado (H1)	Novo cálculo de percentual de atraso, nota média e tempo de entrega por estado do cliente, com tabela 24_h1_atraso_por_uf.csv e Gráfico 11. Transforma a hipótese geográfica da EDA em evidência.
Testes estatísticos em tabela	Os coeficientes de Spearman e o teste de Kruskal-Wallis, antes exibidos apenas no terminal, passaram a ser gravados em 23_h1_testes_estatisticos.csv.
Rótulo dos quadrantes (H2)	O quadrante "Risco: muita receita, nota baixa" passou a se chamar "Atenção: receita alta, nota abaixo da mediana", alinhado ao critério estatístico adotado.
README	Reescrito com a pergunta do projeto, principais resultados, estrutura de pastas, instruções de execução e decisões de método.
Dashboard	Layout reorganizado na ordem do storytelling, com números no padrão brasileiro, cores consistentes por faixa de atraso e correção da largura dos gráficos em abas ocultas. Os dados exibidos não foram alterados.
Versionamento	Criada a release etapa-3 no GitHub, que registra a versão do código entregue nesta etapa.

7.2 RESULTADOS DA REVISÃO

O teste de Kruskal-Wallis entre as cinco faixas de atraso resultou em $H = 10.127,28$ com $p < 0,001$, o que indica que as diferenças de nota entre as faixas não se devem ao acaso. A correlação de Spearman entre dias de atraso e nota é de -0,176, valor aparentemente modesto porque 92,01% dos pedidos chegam no prazo e variam de antecedência sem variar de nota; o efeito está concentrado na minoria que atrasa.

A nova análise por estado mostrou correlação de Spearman de -0,821 entre o percentual de atraso e a nota média dos 27 estados. Os estados com maior percentual de atraso são Alagoas (23,35%), Maranhão (19,24%) e Piauí (15,92%), e os de menor nota média são Maranhão (3,83) e Alagoas (3,85). Em São Paulo, onde está a maioria dos vendedores, o atraso é de 5,83% e a nota média de 4,25.

8. REPOSITÓRIO E DASHBOARD

O código desenvolvido está organizado em módulos, com separação entre carga, tratamento, modelagem do banco, análise exploratória, hipóteses e visualização, e pode ser executado integralmente por um único comando. As consultas SQL que reproduzem as principais análises diretamente no banco relacional estão disponíveis em arquivos separados. Os resultados foram consolidados em um painel interativo publicado em acesso aberto.

Repositório: https://github.com/melissalima308/mackenzie-grupo10-projeto-bd
Dashboard: https://melissalima308.github.io/mackenzie-grupo10-projeto-bd/

CRONOGRAMA

Data	Integrante	Atividade Desenvolvida
09/09/2026	Beatriz Resende Silva	Pesquisa sobre a empresa Olist.
09/09/2026	Mayara Laury Gonçalves de França	Levantamento de informações sobre o dataset utilizado.
09/09/2026	Melissa Menchão Lima do Nascimento	Organização da estrutura do trabalho e criação do repositório no GitHub.
09/09/2026	Otavio Prates dos Santos	Análise inicial das tabelas e informações do dataset.
10/09/2026	Todos os integrantes	Revisão e organização do conteúdo do trabalho.
14/09/2026	Todos os integrantes	Revisão final e entrega da primeira etapa do projeto.
28/09/2026	Beatriz Resende Silva	Preparar a seção de proposta analítica.
28/09/2026	Mayara Laury Gonçalves de França	Estudo das bibliotecas de gráfico e visualização.
28/09/2026	Melissa Menchão Lima do Nascimento	Preparar a seção de análise exploratória.
28/09/2026	Otavio Prates dos Santos	Scripts em Python.
02/10/2026	Todos os integrantes	Revisão final e entrega da segunda etapa do projeto.
05/10/2026	Todos os integrantes	Revisão e organização da etapa 1 + etapa 2.
03/11/2026	Todos os integrantes	Preparo e organização do esboço do Storytelling para apresentação
09/11/2026	Todos os integrantes	Revisão e organização da Etapa 02 + 03.

REFERÊNCIAS

Olist

OLIST. Sobre a Olist: nossa missão é fortalecer o comércio no mundo. Disponível em: https://olist.com/sobre-nos/. Acesso em: 9 set. 2026.

Dataset

OLIST. Brazilian E-Commerce Public Dataset by Olist. Kaggle, Version 2. Disponível em: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce/data. Acesso em: 9 set. 2026.

Notícias e reportagens

BLOOMBERG LÍNEA. Olist cria divisão de logística e aposta em frete como nova alavanca de crescimento. Disponível em: https://www.bloomberglinea.com.br/startups/olist-cria-divisao-de-logistica-e-aposta-em-frete-como-nova-alavanca-de-crescimento/. Acesso em: 9 set. 2026.

Dados corporativos

CB INSIGHTS. Olist – Founded Year, Funding & Overview. Disponível em: https://www.cbinsights.com/investor/solidarium. Acesso em: 9 set. 2026.

Análises de terceiros sobre o dataset

ABBAS, Muhab. Brazilian E-Commerce Public Dataset by Olist. Medium. Disponível em: https://medium.com/@muhab.abbas11/brazilian-e-commerce-public-dataset-by-olist-9757bc7964a4. Acesso em: 9 set. 2026.

GITHUB. noturbob/Olist-Ecommerce-Analysis. Disponível em: https://github.com/noturbob/Olist-Ecommerce-Analysis. Acesso em: 9 set. 2026.